UNIVERSIDADE DO VALE DO RIO DOS SINOS (UNISINOS)
ENGENHARIA DA COMPUTAÇÃO

MAURO DE MOURA

DETECÇÃO DE DRONES COM VISÃO COMPUTACIONAL:
Análise comparativa de modelos YOLOv8 com e sem Data Augmentation

São Leopoldo
2026

1 INTRODUÇÃO

O uso de drones tem crescido significativamente nos últimos anos, impulsionados por avanços tecnológicos e ampla disponibilidade desses dispositivos. Atualmente, drones são utilizados em diversas áreas, como monitoramento ambiental, inspeções industriais, logísticas e aplicações de segurança. No entanto, isso traz um novo desafio, especialmente no contexto de monitoramento do espaço aéreo e identificação de objetos não autorizados.

Em cenários críticos, como áreas sensíveis e de acesso restrito, a presença de drones pode representar riscos operacionais e de segurança, tornando necessários sistemas capazes de detectar esses dispositivos de forma automática e eficiente. Esse problema se torna mais complexo devido às características dos drones em imagens reais, como tamanho reduzido, variabilidade de aparência e a presença de fundos visuais complexos.

Nesse contexto, as técnicas de visão computacional baseadas em aprendizado profundo têm se mostrado uma abordagem promissora para a detecção de objetos em imagens. Entre essas técnicas, o modelo YOLO (You Only Look Once) é amplamente utilizado devido sua capacidade de realizar detecção em tempo real, mantendo bom equilíbrio entre desempenho e custo computacional.

Dessa forma, esse trabalho tem como objetivo desenvolver um sistema de detecção de drones utilizando o modelo YOLOv8, bem como analisar o impacto do uso de técnicas de data augmentation no desempenho do modelo. Para isso foram treinadas duas versões do modelo: uma utilizando o conjunto de dados original e outra com a aplicação de técnicas de aumento de dados.

A avaliação dos modelos foi realizada por meio de métricas quantitativas, como precision, recall, F1-score e IoU, além de análises qualitativas das detecções geradas. Além disso, forma conduzidos testes variando o limiar de confiança das predições, permitindo investigar o comportamento dos modelos sob diferentes condições operacionais.

2 METODOLOGIA

2.1 DATASET

O conjunto de dados utilizados neste trabalho foi obtido a partir de fontes disponíveis na internet, contendo imagens de drones em cenários reais. As imagens apresentam diferentes condições ambientais, incluindo variações de iluminação, fundo e escala dos objetos, tornando o problema de detecção mais desafiador e próximo de aplicações reais.

Durante a análise do dataset, observou-se que as anotações (bounding boxes) associadas aos drones frequentemente apresentavam dimensões superiores ao objeto real, resultando em delimitações mais amplas do que o necessário. Essa característica impacta diretamente a avaliação do modelo, especialmente em métricas baseadas em interseção sobre união (IoU), já que predições mais precisas podem ser penalizadas.

2.2 MODELOS

Para a tarefa de detecção de objetos, foi utilizado o modelo YOLOv8, uma arquitetura moderna de redes neurais convolucionais voltada para detecção em tempo real.

Foram treinadas duas versões do modelo com o objetivo de analisar o impacto do uso de técnicas de aumento de dados (data augmentation):

- Modelo 1: treinado utilizando o dataset original, sem aplicação de data augmentation;
- Modelo 2: treinado com o mesmo dataset, porém utilizando a técnica de aumento de dados durante o treinamento.

Essa abordagem permitiu uma comparação direta entre os dois cenários, mantendo constantes as demais variáveis do processo.

2.3 TREINAMENTO

O treinamento dos modelos foi realizado utilizando o mesmo conjunto de dados, com parâmetros idênticos, de modo a garantir uma comparação justa entre as abordagens. Ambos os modelos foram treinados pelo mesmo número de épocas (50), utilizando as mesmas configurações de entrada e arquitetura base.

As imagens foram redimensionadas para resolução de 640x640 pixels, conforme o padrão utilizado pelo modelo YOLOv8. O processo de treinamento foi conduzido até a convergência dos modelos, sendo selecionadas as melhores versões com base no desempenho observado.

2.4 AVALIAÇÃO

A avaliação dos modelos foi realizada utilizando um script próprio desenvolvido em Python, denominado evaluate.py, aplicado sobre um conjunto de teste distinto do utilizado no treinamento, evitando assim problemas de data leakage.

Forma utilizadas as seguintes métricas para a avaliação do desempenho:

- Precision: proporção de detecções corretas em relação ao total de detecções realizadas;
- Recall: proporção de objetos corretamente detectados em relação ao total de objetos presentes;
- F1-score: média entre precision e recall;
- IoU: medida de sobreposição entre as bounding boxes previstas e as anotações do dataset.

Além da análise quantitativa, também foi realizada avaliação qualitativa por meio de inspeção visual das bounding boxes geradas pelos modelos.

2.5 PARÂMETROS EXPERIMENTAIS

Para analisar o comportamento dos modelos sob diferentes condições, foram realizados experimentos variando o limiar de confiança das detecções. Foram avaliados valores entre 0.1 e 0.9, com incrementos de 0.2.

Adicionalmente, foi utilizado um limiar de IoU igual a 0.2 durante a avaliação. Essa escolha foi motivada pela presença de anotações imprecisas no dataset, conforme discutido anteriormente, permitindo uma avaliação mais alinhada com a qualidade visual das detecções.

As imagens de saída com as bounding boxes geradas foram armazenadas para diferentes valores de confiança, possibilitando uma análise comparativa visual entre os modelos.

3 RESULTADOS

3.1 ANÁLISE QUALITATIVA DAS DETECÇÕES

Foram selecionados quatro cenários representativos para análise qualitativa:

- Cenário A: drone em fundo de céu limpo, com boa visibilidade e maior proximidade do objeto;
- Cenário B: drone mais distante, com fundo de céu nublado e maior complexidade visual;
- Cenário C: drone distante em céu parcialmente limpo;
- Cenário D: presença de dois drones em céu limpo.

Esses cenários permitem avaliar o comportamento dos modelos em situações de maior dificuldade e em casos com múltiplas instâncias do objeto.

Em um limiar de confiança mais permissivo, ambos os modelos apresentaram capacidade de detecção consistente, porém com diferenças relevantes na qualidade das bounding boxes.

No cenário A, o modelo sem data augmentation gerou uma bounding box levemente ajustada ao objeto, com pequeno corte em partes do drone, priorizando a região central. Já o modelo com augmentation apresentou uma delimitação mais precisa, cobrindo completamente o drone sem incluir áreas excessivas.

No cenário B, onde o drone se apresentava como um objeto pequeno e com menor definição visual, as diferenças tornam-se mais evidentes. O modelo sem augmentation produziu bounding boxes maiores que o objeto, englobando uma área além do drone. Já o modelo com augmentation gerou caixas significativamente mais ajustadas, aproximando-se do tamanho real do objeto, mesmo em condições de baixa visibilidade.

No cenário C, o modelo sem data augmentation não detectou o drone presente na imagem e apresentou um falso positivo ao identificar uma pequena nuvem como objeto. Em contraste, o modelo com augmentation detectou corretamente o drone distante, utilizando uma bounding box bem ajustada ao objeto.

No cenário D, contendo dois drones, o modelo sem augmentation identificou corretamente ambos, porém gerou uma detecção adicional incorreta, caracterizando um falso positivo. Já o modelo com augmentation detectou corretamente os dois drones, sem apresentar detecções espúrias, além de gerar bounding boxes mais precisas.

Ao aumentar o limiar de confiança, observa-se uma mudança no comportamento dos modelos.

No cenário A, ambos os modelos continuam detectando o drone de forma consistente. O modelo sem augmentation apresentou uma bounding box ligeiramente mais ampla em comparação ao caso anterior, enquanto o modelo com augmentation manteve uma delimitação um pouco mais ajustada, embora a diferença entre os dois modelos seja menos perceptível nesse cenário.

No cenário B, a diferença entre os modelos se torna crítica. O modelo sem augmentation manteve a capacidade de detecção, ainda que com bounding boxes mais amplas que o objeto. Por outro lado, o modelo com data augmentation não realizou a detecção do drone nesse cenário, indicando perda de sensibilidade em condições mais desafiadoras quando utilizado um threshold de confiança mais elevado.

No cenário C, nenhum dos modelos foi capaz de detectar o drone, evidenciando a dificuldade da tarefa em condições de baixa visibilidade quando o threshold de confiança é elevado.

No cenário D, o modelo sem augmentation detectou apenas um dos drones presentes na imagem, enquanto o modelo com augmentation conseguir identificar corretamente ambos os objetos, mantendo bounding boxes ajustadas

Durante a análise qualitativa, foi identificado um comportamento anômalo no modelo com data augmentation em uma imagem específica com threshold de confiança de 0.1. Nesse caso, o modelo detectou corretamente um drone distante, porém também gerou uma bounding box adicional de grandes dimensões, sobrepondo-se à região da imagem e resultando em uma detecção duplicada e incorreta do objeto.

Esse tipo de comportamento não foi observado no modelo sem augmentation, que embora apresente maior número de falsos positivos em alguns cenários, não demonstrou esse padrão de detecção sobreposta.

Os resultados evidenciam que o uso de data augmentation melhora a capacidade de generalização e a precisão espacial das detecções, porém pode introduzir maior variabilidade no comportamento do modelo, incluindo sensibilidade ao threshold e ocorrência de detecções inconsistentes em cenários específicos.

3.2 ANÁLISE QUANTITATIVA DOS RESULTADOS

3.2.1 Avaliação geral em função do threshold de confiança

Foram realizados experimentos variando o limiar de confiança entre 0.1 e 0.9, com o objetivo de analisar o comportamento dos modelos sob diferentes critérios de decisão.

De forma geral, observou-se que ambos os modelos apresentam o comportamento esperado de sistemas de detecção: o aumento do threshold de confiança resulta em aumento da precisão e redução de recall. No entanto, a forma como essa variação ocorre difere significativamente entre os modelos analisados.

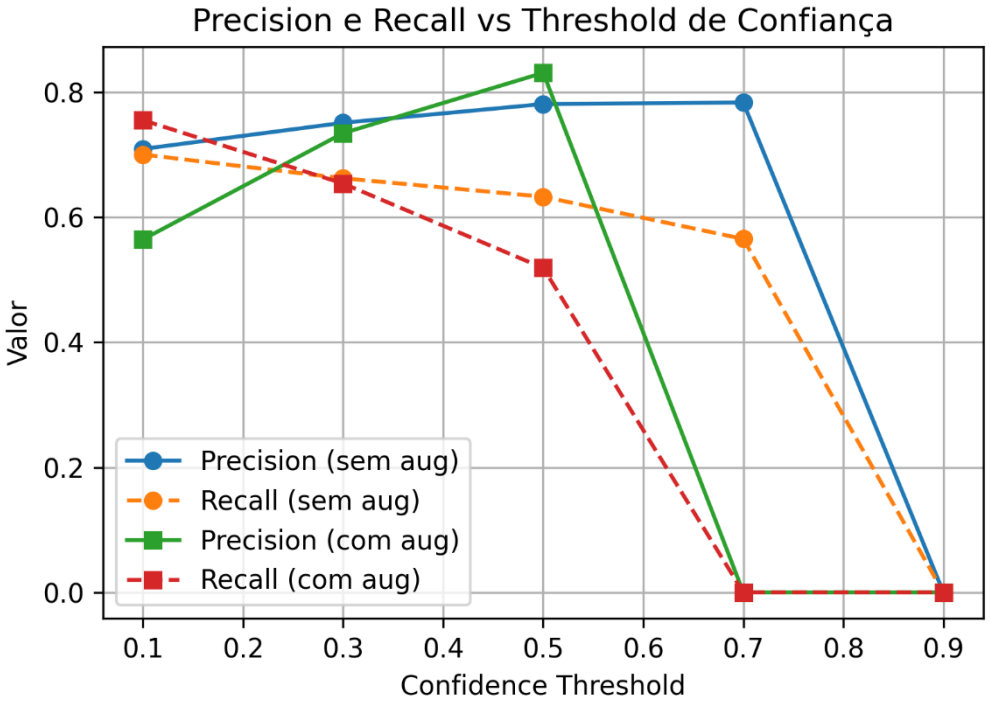

FIGURA 1 – VARIAÇÃO DE PRECISION E RECALL EM FUNÇÃO DO THRESHOLD DE CONFIANÇA PARA AMBOS OS MODELOS.

3.2.2 Modelo sem data augmentation

O modelo baseline apresentou comportamento estável ao longo da variação do threshold de confiança.

Em valores baixos de confiança, o modelo apresentou equilíbrio entre precisão e recall, com F1-score elevado. À medida que o threshold aumenta, observa-se um crescimento gradual da precisão, acompanhado de uma redução moderada no recall. Ainda assim, o modelo mantém capacidade de detecção mesmo em valores mais elevados de confiança (até 0.7), demonstrando robustez.

Esse comportamento indica que o modelo sem augmentation tende a atribuir níveis de confiança mais elevados às suas predições, mantendo consistência mesmo sob critérios mais restritivos.

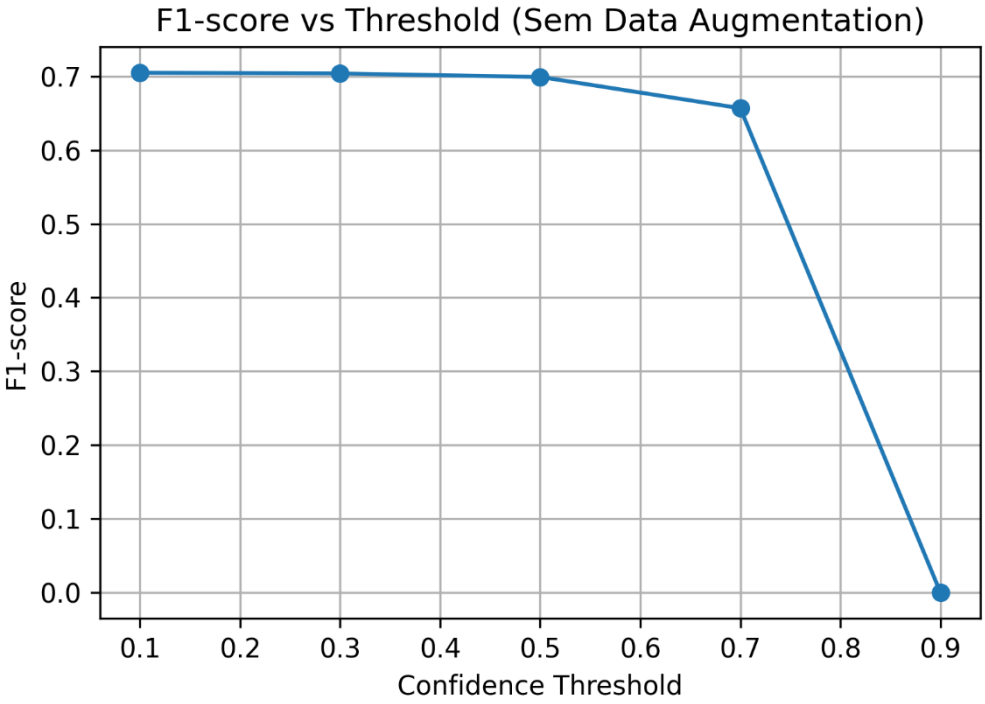

FIGURA 2 – F1-SCORE EM FUNÇÃO DO THRESHOLD DE CONFIANÇA PARA O MODELO SEM DATA AUGMENTATION.

3.2.3 Modelo com data augmentation

O modelo treinado com data augmentation apresentou um comportamento distinto, caracterizado por maior sensibilidade à variação do threshold de confiança.

Em valores baixos, o modelo apresentou alto recall, indicando boa capacidade de detecção, especialmente em cenários com objetos pequenos ou difíceis. No entanto, à medida que o threshold aumenta, observou-se uma queda acentuada no recall, chegando à ausência de detecções em valores mais elevados (0.7 e 0.9).

Embora o modelo apresente maior precisão em determinados pontos (como observados em 0.5), sua capacidade de detecção torna-se significativamente reduzida em cenários mais restritivos.

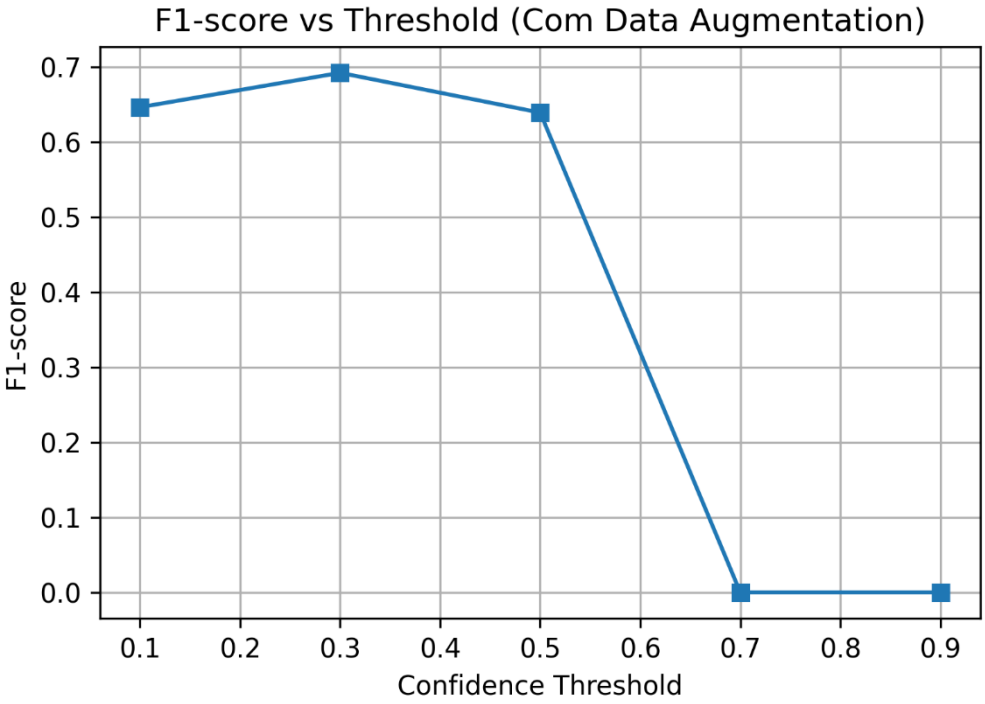

FIGURA 3 – F1-SCORE EM FUNÇÃO DO THRESHOLD DE CONFIANÇA PARA O MODELO COM DATA AUGMENTATION.

3.2.4 Comparação entre os modelos

A comparação direta entre os modelos mostra um trade off claro entre robustez e precisão espacial.

O modelo sem augmentation apresentou melhor desempenho geral em termos de F1-score ao longo da maioria dos threshold, mantendo equilíbrio entre precisão e recall. Por outro lado, o modelo com data augmentation demonstrou maior precisão em determinados pontos, além de melhor qualidade nas bounding boxes, conforma observado na análise qualitativa.

Entretanto, o modelo com augmentation apresentou maior instabilidade em relação ao threshold de confiança, com degradação acentuada do desempenho em valores mais elevados.

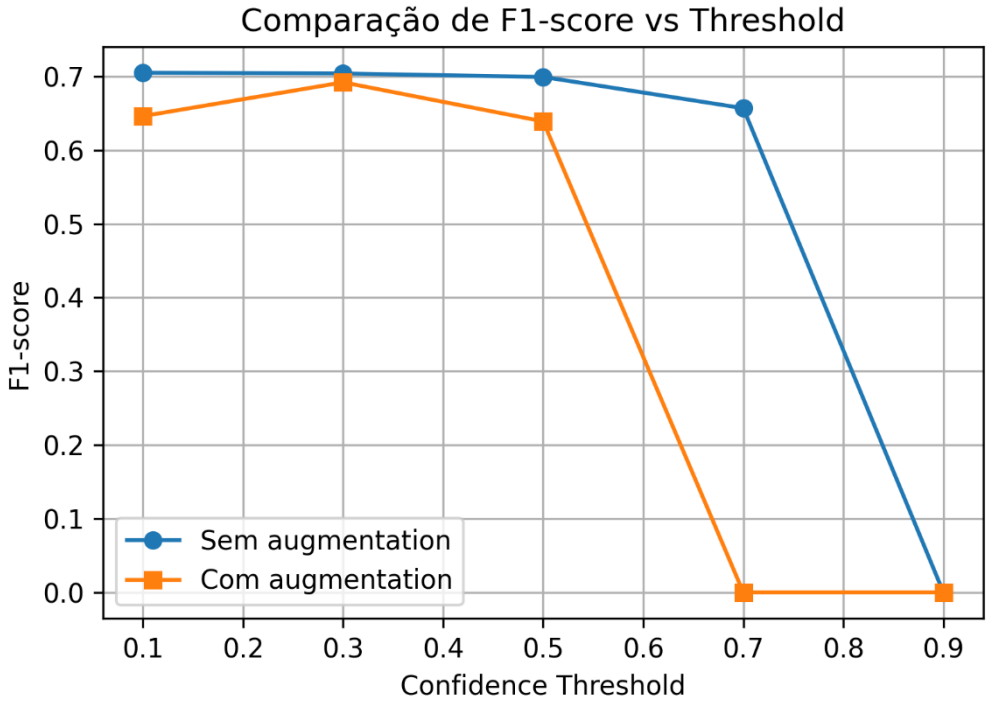

FIGURA 4 – COMPARAÇÃO DO F1-SCORE ENTRE OS MODELOS COM E SEM DATA AUGMENTATION AO LONGO DOS DIFERENTES THRESHOLDS DE CONFIANÇA.

3.2.5 Análise do F1-score

O F1-score, por combinar precisão e recall, permite uma avaliação mais equilibrada do desempenho dos modelos.

Observou-se que o modelo sem augmentation mantém valores F1-score relativamente constantes entre os threshold de 0.1 a 0.5, indicando estabilidade. Já o modelo com augmentation apresenta F1-score competitivo em threshold baixos e intermediários, mas sofre queda significativa à medida que o threshold aumenta.

3.2.6 Considerações sobre o IoU

A avaliação foi realizada utilizando um limiar de IoU igual à 0.2, devido as limitações observadas nas anotações do dataset.

Essa escolha permitiu uma avaliação mais coerente com a qualidade visual das detecções, especialmente considerando que o modelo com augmentation frequentemente produziu bounding boxes mais ajustadas ao objeto, o que poderia resultar em penalização indevida sob critérios mais rígidos.

4 CONCLUSÃO

O presente trabalho teve como objetivo desenvolver e analisar um sistema de detecção de drones utilizando o modelo YOLOv8, com foco no impacto do uso de data augmentation no desempenho do modelo. Para isso, foram comparadas duas abordagens: uma utilizando o dataset original e outra com aplicação de técnica de aumento de dados.

Os resultados obtidos evidenciam a existência de um troca entre precisão, capacidade de detecção e robustez. O modelo treinado sem data augmentation apresentou maior estabilidade ao longo da variação do threshold de confiança, mantendo desempenho consistente em termos de F1-score e capacidade de detecção mesmo em cenários mais desafiadores. Por outro lado, o modelo com data augmentation demonstrou melhor precisão espacial nas bounding boxes e maior capacidade de generalização em cenários permissivos, embora tenha apresentado maior sensibilidade ao aumento do threshold, resultando em perda significativa de recall em valores mais elevados.

A análise qualitativa reforçou esses resultados, mostrando que o modelo com augmentation tende a produzir delimitações mais ajustadas aos objetos, enquanto o modelo baseline mantém maior robustez em condições adversas, como objetos pequenos ou com baixa visibilidade. Também foram observados casos de falsos positivos e comportamentos anômalos, indicando limitações associadas tanto ao modelo quanto à qualidade do dataset utilizado.

Um fator relevante identificado durante o desenvolvimento foi a qualidade das anotações do dataset, que apresentavam bounding boxes maiores que o objeto real. Essa característica impactou diretamente a avaliação baseada em IoU, exigindo o uso de um limiar mais permissivo para melhor refletir a qualidade visual das detecções.

Para aplicações reais, especialmente em cenários de monitoramento e segurança de espaço aéreo, recomenda-se o uso de datasets mais diversificados, contendo diferentes condições ambientais, escalas e níveis de complexidade. Além disso, a inclusão de múltiplas classes, como aves e aeronaves, pode contribuir para a redução de falsos positivos, aumentando a confiabilidade do sistema.

Por fim, destaca-se que a escolha do modelo e dos parâmetros operacionais, como o threshold de confiança, deve considerar o contexto da aplicação. Em cenários onde a detecção de todos os objetos é crítica, pode ser preferível utilizar configurações mais permissivas. Já em aplicações onde a precisão é crítica, abordagens mais conservadoras são ideais.

REFERÊNCIAS

Kaggle. Drone Dataset UAV. Disponível em: https://www.kaggle.com/datasets/dasmehdixtr/drone-dataset-uav

. Acesso em: 13 abr. 2026;

Kaggle. Drone Detection Dataset. Disponível em: https://www.kaggle.com/datasets/cybersimar08/drone-detection

. Acesso em: 13 abr. 2026;

Ultralytics. YOLOv8 Documentation. Disponível em: https://docs.ultralytics.com

. Acesso em: 13 abr. 2026.